

Big Data - Analisis Exploratorio de Datos

Utilizando la herramienta Orange Data Mining, importe el archivo de datos hogares.csv y elabore un informe con las respuestas a las preguntas indicadas en esta guía.

Hogares.csv contiene datos ficticios de 100 hogares encuestados.

Condiciones de entrega

- Entrega Grupal: Deben entregarlo por Github con el nombre del grupo
- Plazo máximo: hasta la siguiente clase.

Diccionario de Datos

HogarID: Identificador único del hogar, entero que va de 1 a 100.

IngresoMensual: Ingresos totales del hogar por mes, en pesos argentinos (ARS). Representa la suma de todos los ingresos de los miembros del hogar.

GastoMensual: Gastos totales del hogar por mes, en pesos argentinos (ARS). Incluye gastos fijos (como alquiler o hipoteca, servicios, etc.) y gastos variables (como alimentación, transporte, ocio).

NumPersonas: Número de personas que conforman el hogar. Valor entero que indica la cantidad de individuos viviendo en el hogar.

TipoVivienda: Tipo de estructura habitacional donde reside el hogar. Puede ser "Casa" o "Departamento", reflejando las diferentes modalidades de vivienda.

ZonaVivienda: Zona geográfica donde se ubica el hogar. Las categorías incluyen "Urbana", "Suburbana" y "Rural", indicando el contexto geográfico y posiblemente socioeconómico de la vivienda.

EdadPromedioHogar: Edad promedio de los miembros del hogar, en años. Esta variable es un promedio de las edades de todos los individuos que conforman el hogar.

Guía de Preguntas

1. Análisis de Tendencia Central y Dispersión (Feature Statistics y Distributions):

Calcule las medidas de tendencia central (media, mediana) y dispersión (varianza, desviación estándar) para las variables IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Los valores encontrados son consistentes con lo que esperarías en un contexto económico real?

2. Verificación de Máximos y Mínimos (Feature Statistics):

Identifique los valores máximos y mínimos para IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Estos valores son realistas? Discuta cualquier valor que parezca inusual o fuera de lo esperado.

3. Relación entre Variables (Scatter Plot):

Explore la relación entre el EdadPromedioHogar y otras variables numéricas como IngresoMensual y GastoMensual. ¿Hay alguna tendencia visible que indique cómo la edad promedio del hogar afecta los ingresos y gastos?

4. Análisis de Outliers (Box Plot):

Utilizando técnicas gráficas, identificar datos atípicos en las variables numéricas. Describa por qué estos puntos podrían considerarse atípicos y qué factores podrían explicar estos valores.

5. Comparación entre Grupos (Box Plot):

Analice cómo varía la EdadPromedioHogar entre diferentes tipos de vivienda (Casa, Departamento) y zonas de vivienda (Urbana, Suburbana, Rural). ¿Existen diferencias significativas que puedan sugerir patrones demográficos?

6. Correlaciones (Correlations):

Investigue la correlación entre las variables numéricas. ¿Qué relaciones se pueden identificar como relevantes y cómo se interpretan?

RESPUESTAS

1) Análisis de Tendencia Central y Dispersión (Feature Statistics y Distributions): Calcule las medidas de tendencia central (media, mediana) y dispersión (varianza, desviación estándar) para las variables

IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Los valores encontrados son consistentes con lo que esperarías en un contexto económico real?

Column Statistics									
	Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing
N	NumPersonas		2.88	1	3	0.49	1	5	0 (0 %)
N	EdadPromed...		40.192	36	38	0.411913	-5	120	0 (0 %)
N	HogarID		50.50	1	50.50	0.57	1	100	0 (0 %)
N	GastoMensual		62151.3	20623.9	62352.3	0.401912	20623.9	127691	0 (0 %)
N	IngresoMens...		91719.8818	40607.43	91055.67	0.3550	40607.43	148557.56	0 (0 %)
G	TipoVivienda			Departamento		0.691			0 (0 %)
G	ZonaVivienda			Suburbana		1.1			0 (0 %)

IngresoMensual:

- media= 91719.8818 \$
- mediana= 91055.67 \$
- dispersion= 0.3550

GastoMensual:

- media = 62151.3 \$
- mediana= 62352.3 \$
- dispersión= 0.401912

EdadPromedioHogar:

- media = 40.192 años
- mediana= 38 años
- dispersión= 0.411913

Los valores encontrados son consistentes con lo que se esperaría en un contexto económico real. Podemos ver que la media y mediana son cercanas entre sí, tanto en los ingresos como en los gastos, lo que indica que están bastante equilibrados. Además, tiene sentido que el GastoMensual sea menor que el IngresoMensual ya que en un contexto real, las familias suelen destinar parte de sus ingresos al ahorro, o no gastan más de lo que tienen.

2. Verificación de Máximos y Mínimos (Feature Statistics): Identifique los valores máximos y mínimos para IngresoMensual, GastoMensual, y EdadPromedioHogar. ¿Estos valores son realistas? Discuta cualquier valor que parezca inusual o fuera de lo esperado.

IngresoMensual:

- valores máximos: 148557.56
- valores mínimos: 40607.43

GastoMensual:


- valores máximos: 127691
- valores mínimos: 20623.9

EdadPromedioHogar:

- valores máximos: 120
- valores mínimos: -5

Los valores en cuanto a los ingresos y gastos si parecen razonables y lógicos, pero los valores de EdadPromedioHogar son realistas. Edad promedio de -5 años es imposible y de 120 años es poco realista, por ende, esto evidencia que el dataset de hogares.csv contiene ciertos errores de carga que si deberían limpiarse antes de seguir analizando

3. Relación entre Variables (Scatter Plot): Explore la relación entre el EdadPromedioHogar y otras variables numéricas como IngresoMensual y GastoMensual. ¿Hay alguna tendencia visible que indique cómo la edad promedio del hogar afecta los ingresos y gastos?




En cuanto a la comparación de edad con ingreso mensual, al observar los puntos vemos que están desparramados de forma vertical, no hay una tendencia ascendente ni descendente que esté bien marcada. Los ingresos parecen estar distribuidos de forma uniforme entre los distintos rangos de edad, hay ingresos altos en hogares donde la edad se encuentra en el rango de 30-60 años.

También se puede ver que en los extremos del eje x se aprecian los puntos aislados que son aquellos datos atípicos mencionados anteriormente lo que serían los outliers.


En cuanto a la comparación de edad con gasto mensual, vemos que es parecida a la relación con los ingresos, solo que vemos que los gastos son en menor medida. Se puede ver que no hay una correlación fuerte.

4. Análisis de Outliers (Box Plot):

Utilizando técnicas gráficas, identificar datos atípicos en las variables numéricas. Describa por qué estos puntos podrían considerarse atípicos y qué factores podrían explicar estos valores.




En el BoxPlot de EdadPromedioHogar se observan valores atípicos extremos, destacándose un límite inferior con números negativos y un límite superior que se extiende hasta los 120 años. Estos puntos se consideran atípicos porque escapan por completo de la realidad (como ya mencionamos). Estos valores pueden explicarse por errores de tipeo o fallas en la generación del dataset, lo que evidencia datos sucios que se deben limpiar.




En el BoxPlot de IngresoMensual se muestra una distribución donde los valores que se alejan hacia el extremo superior representan a hogares con ingresos superiores al promedio. Estos puntos se consideran atípicos ya que estan bastante alejados. Los factores que lo explican pueden ser los hogares con alto poder adquisitivo o sesgos en la distribución económica de la encuesta, reflejando la desigualdad real de ingresos o valores inflados por errores de carga.



En el BoxPlot de GastoMensual se identifican valores atípicos en los extremos superiores de la distribución (superando los \$120.000 frente a una media de \$62.151). Estos puntos son atípicos porque se distancian del comportamiento general de consumo de la mayoría de los hogares encuestados. Esto podría explicarse por hogares con un nivel de vida sumamente elevado, grandes familias o situaciones financieras particulares (como deudas o inversiones registradas como gasto), o por desvíos en la recolección de los datos.




En el BoxPlot de NumPersonas, el rango se mantiene acotado de manera realista entre 1 y 5 individuos (con una media de 2,88) sin presentar valores absurdos. Estos valores responden a la diversidad en la composición familiar real (personas que viven solas o familias numerosas) y no necesariamente a un error de carga, sino a la variabilidad demográfica natural.




En el BoxPlot de HogarID, el diagrama muestra una distribución perfectamente uniforme y simétrica que abarca desde el valor 1 hasta el 100, coincidiendo exactamente con los 100 hogares encuestados del dataset. No hay valores atípicos.

5. Comparación entre Grupos (Box Plot):

Analice cómo varía la EdadPromedioHogar entre diferentes tipos de vivienda (Casa, Departamento) y zonas de vivienda (Urbana, Suburbana, Rural). ¿Existen diferencias significativas que puedan sugerir patrones demográficos?




Al analizar la EdadPromedioHogar dividida por el tipo de vivienda, se observa que los hogares que residen en Departamentos presentan una edad promedio ligeramente mayor (43,09 años, con una mediana de 41,6) en comparación con aquellos que habitan en Casas (36,92 años de media y una mediana de 34,3). Además, los departamentos muestran una mayor dispersión o variabilidad en las edades. Esto puede sugerir un patrón demográfico donde los departamentos concentran a adultos mayores o parejas sin hijos, mientras que las casas tienen familias más jóvenes con niños.



Al comparar por zona geográfica, con ZonaVivienda, se pueden identificar diferencias en las estructuras familiares según el entorno. En la zona urbana se ve que la edad promedio es de gente adulta joven, ya que el rango es más acotado y podría representar estudiantes o trabajadores de ciudad. En la zona suburbana, vemos que el rango es más extendido ya que podría representar familias más establecidas, al igual que en la zona rural, aunque en rural la media es de una edad mayor.

6. Correlaciones (Correlations):

Investigue la correlación entre las variables numéricas. ¿Qué relaciones se pueden identificar como relevantes y cómo se interpretan?



a) La correlación más importante ocurre entre GastoMensual e IngresoMensual ya que es la más cercana a 1, lo cual indica una correlación muy positiva y muy fuerte. Significa que a mayor ingreso, mayor es el gasto en el hogar

b) Las demás correlaciones vemos que ya son más bajas debido a que están más cercanas a 0, por lo que la correlación es baja o directamente (en aquellos que son negativos) indica que no hay relación lineal significativa entre esas variables