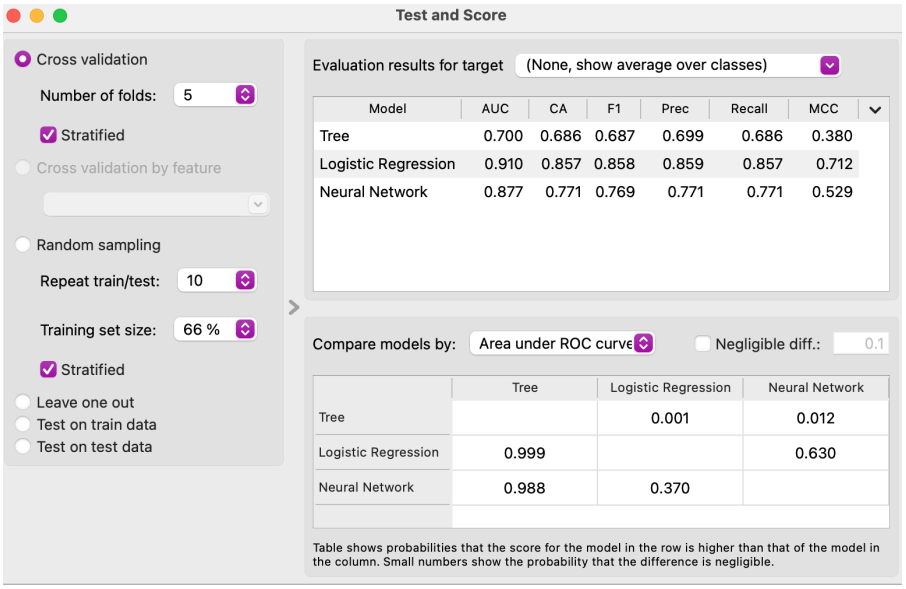
1. **Métricas (precision, recall, accuracy, F1)**



Regresión Logística:

- Accuracy (CA): 0.857
- Precisión: 0.859
- Recall (Sensibilidad): 0.857
- F1-Score: 0.858
- AUC: 0.910

Es el modelo más sólido y equilibrado, demostrando que la relación entre las variables nutricionales y el tipo de alimento se modela bien de forma lineal.

Red Neuronal:

- Accuracy (CA): 0.771
- Precisión: 0.771
- Recall (Sensibilidad): 0.771
- F1-Score: 0.769
- AUC: 0.877

Presenta un desempeño intermedio, pero con una tasa de error superior a la regresión logística en la validación cruzada.

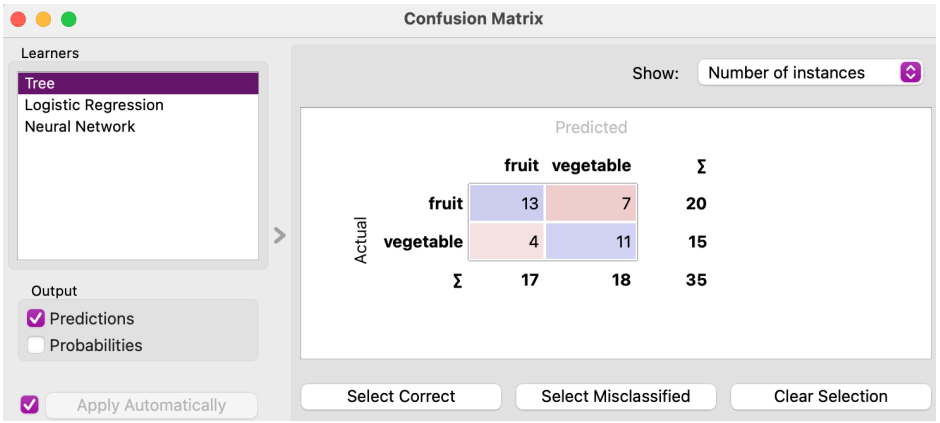
Árbol de Decisión (Tree):

- Accuracy (CA): 0.686
- Precisión: 0.699
- Recall (Sensibilidad): 0.686
- F1-Score: 0.687
- AUC: 0.700

Es el modelo más débil. Se dificulta capturar la continuidad de las variables de nutrientes.

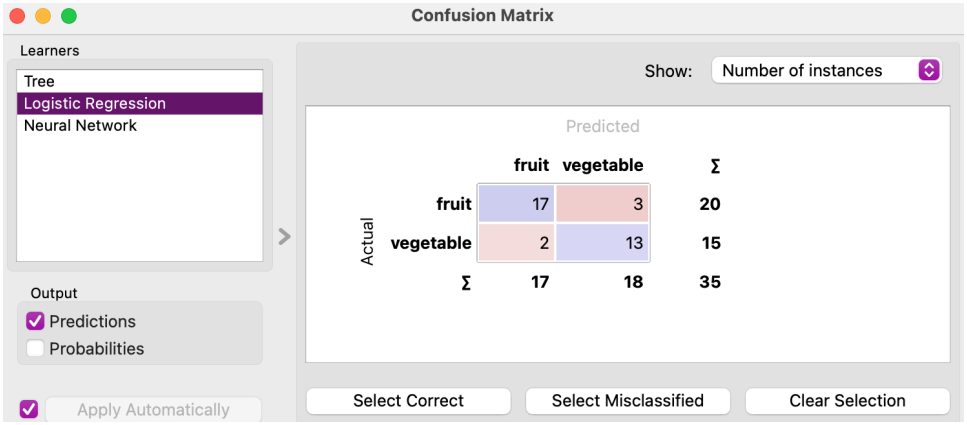
2. Matriz de confusión

Tree



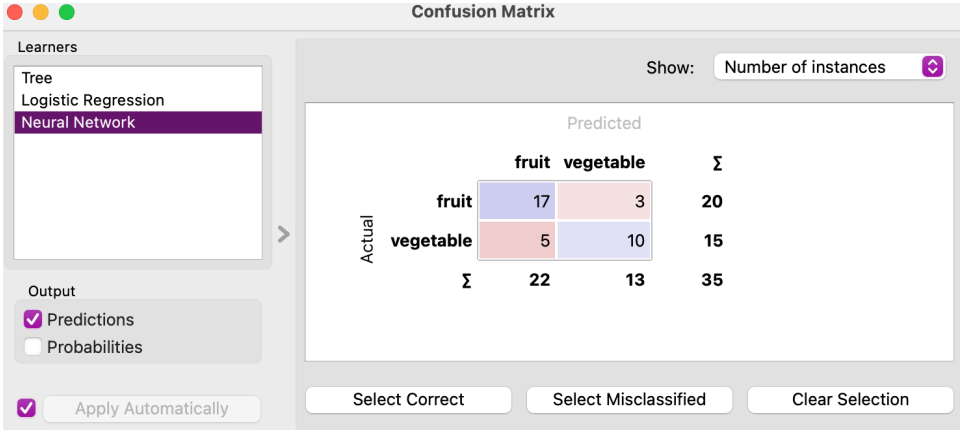
El Árbol de Decisión presenta el rendimiento más flojo. De las 20 frutas reales, el modelo solo acierta 13 y deja pasar 7 (siendo falsos negativos). Además, confunde 4 vegetales clasificándolos como fruta, siendo falsos positivos. Esto evidencia que los cortes rígidos del árbol no logran capturar correctamente las relaciones continuas de los nutrientes.

Logistic Regression



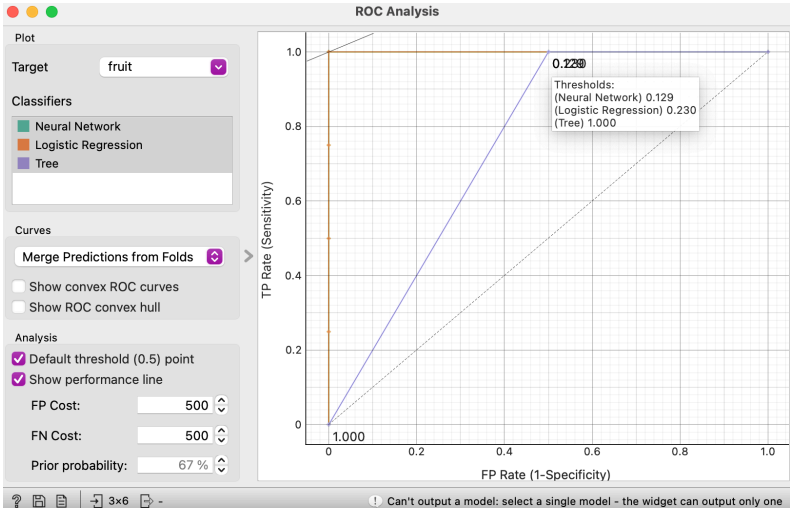
La Regresión Logística demuestra ser el mejor modelo de los tres. Logra clasificar correctamente 30 de 35 instancias totales. Reduce los errores a solo 3 falsos negativos y 2 falsos positivos, confirmando que la relación entre los datos nutricionales y las clases, es lineal y se adapta bien.

Neural Network



La Red Neuronal muestra un desempeño intermedio, 27 aciertos de 35. Es igual con la regresión logística en su capacidad de detectar frutas reales (17 aciertos y 3 falsos negativos), pero comete 5 falsos positivos, es decir confundiendo 5 vegetales con frutas, lo que hace que sea un mayor error.

3. Área debajo de la curva

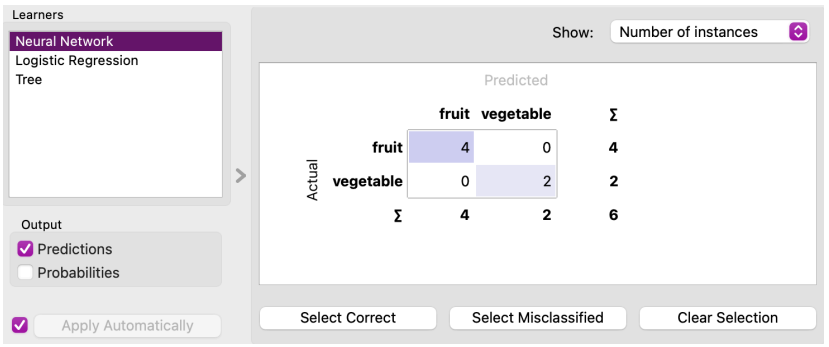


En el gráfico ROC se observa el rendimiento de los tres modelos sobre el conjunto de prueba:

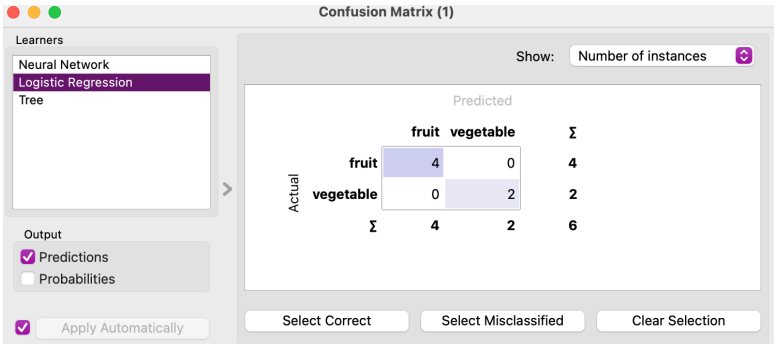
La Red Neuronal y la Regresión Logística alcanzan el comportamiento óptimo con un área bajo la curva perfecta (AUC = 1.000), subiendo de forma vertical y separando las clases sin margen de error. Alcanzan una Tasa de Verdaderos Positivos de 1.0 manteniendo una Tasa de Falsos Positivos de 0.0. Refleja una separación perfecta entre las clases fruit y vegetable.

El Árbol de Decisión (Tree) se desplaza de manera menos óptima, reflejando su menor capacidad de discriminación en comparación con los otros dos algoritmos. Muestra que el árbol necesita tolerar mayor margen de error para poder detectar los casos reales, evidenciando que es el modelo más débil a la hora de separar ambas clases.

4. Analizar FP/FN y que implicancias tiene

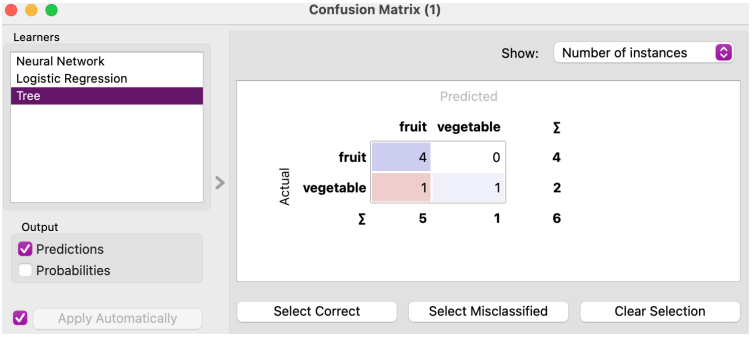


Hay 4 Verdaderos Positivos (frutas), 0 Falsos Negativos, 0 Falsos Positivos, 2 Verdaderos Negativos (vegetales). Total: 6/6 aciertos, es decir, 100%.
La Red Neuronal clasifica de forma correcta las 6 instancias de prueba, sin cometer ningún error de Falso Positivo ni Falso Negativo



Hay 4 Verdaderos Positivos, 0 Falsos Negativos, 0 Falsos Positivos, 2 Verdaderos Negativos. Total: 6/6 aciertos, es decir, 100%.

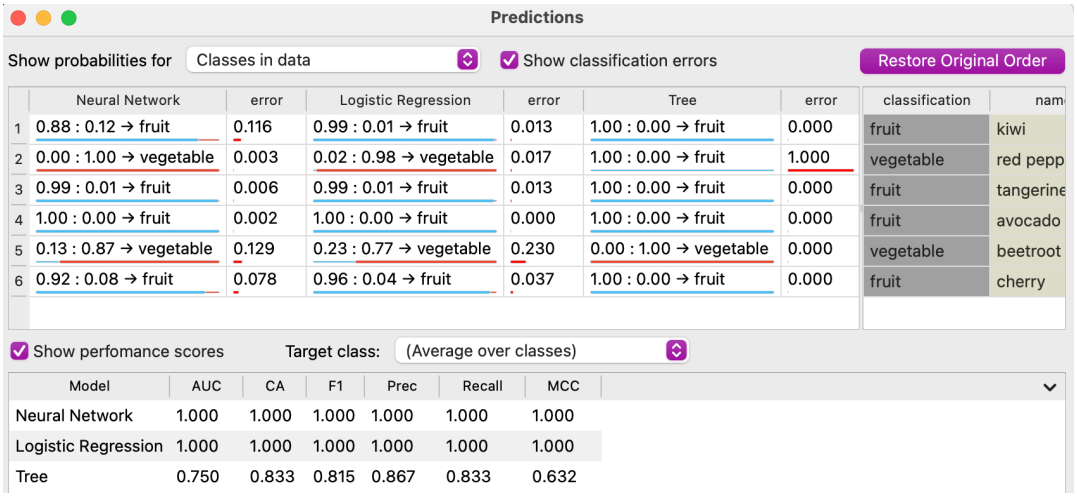
Al igual que la red neuronal, la Regresión Logística logra una efectividad perfecta del 100%, acertando todos los casos sin generar confusión entre frutas y vegetales

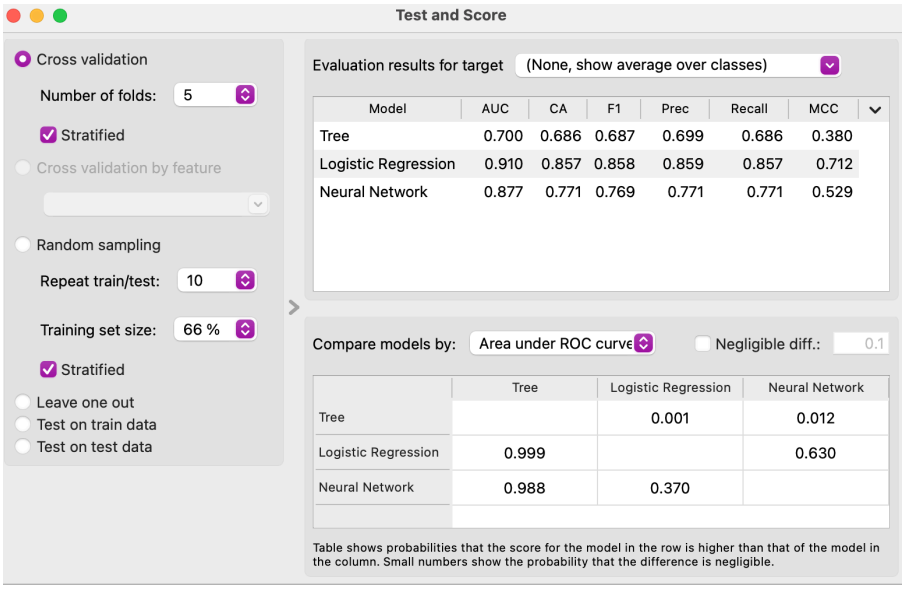


Hay 4 Verdaderos Positivos, 0 Falsos Negativos, 1 Falso Positivo (un vegetal clasificado erróneamente como fruta), 1 Verdadero Negativo. Total: 5/6 aciertos.
El Árbol de Decisión comete un error en esta muestra: presenta 1 Falso Positivo al clasificar un vegetal como si fuera una fruta.

Si este modelo se utilizará para el control automático de calidad o el empaquetado de productos, este falso positivo provocaría un error en la línea de producción o en la base de datos nutricional

5. Underfitting / Overfitting





Underfitting: Se evidencia principalmente en el Árbol de Decisión (Tree). Al observar los resultados, este modelo presenta las métricas más bajas tanto en la fase de validación cruzada/train (0.68-0.70% de Accuracy) como un rendimiento inferior en el conjunto de prueba (0.833 de CA y 1 error al clasificar el vegetal). Esto demuestra que el modelo es demasiado simple o sus cortes rígidos no logran capturar la complejidad de las variables de los datos, quedándose corto en su capacidad de aprendizaje.

Overfitting: No se observa un sobreajuste perjudicial en los modelos de Regresión Logística y Red Neuronal. Estos algoritmos mantienen un rendimiento consistentemente alto y equilibrado durante el train/validación cruzada (0.77 a 0.85 de desempeño) como al enfrentarse a los datos nuevos del conjunto de prueba (donde alcanzan un

desempeño perfecto del 1.000 de aciertos y 1.000 de AUC. Esto indica que ambos modelos generalizan de manera excelente en lugar de memorizar los datos de entrenamiento**.**