

Caso de Estudio 3: Ciudad Inteligente (Smart City)

- Caso de Uso: Gestión del tráfico urbano y seguridad pública.
- Descripción Ampliada: Las ciudades modernas están usando Big Data para mejorar la vida de sus ciudadanos. Un ejemplo es la gestión del tráfico y la seguridad:

- Gestión del Tráfico: Sensores en las calles y cámaras de tráfico recopilan datos de flujo vehicular en tiempo real. Esta información se procesa para ajustar los semáforos de forma dinámica y re-enrutar el tráfico en caso de congestión o accidentes.

- Seguridad Pública: Las cámaras y otros sensores recopilan datos para analizar patrones de movimiento y comportamiento. Utilizando análisis predictivos, las fuerzas de seguridad pueden identificar áreas de alto riesgo para desplegar recursos y prevenir delitos antes de que ocurran. Los datos de llamadas de emergencia, redes sociales y reportes ciudadanos también se integran en este análisis.

- **1. Las 5 V's del Big Data:**

- **Volumen: ¿Qué tipo de datos masivos se generan o manejan? ¿De qué escala hablamos (terabytes, petabytes)?**

En el caso de la aplicación Smart City, se van a generar gran cantidad de datos debido a que se va a obtener información mediante las cámaras de seguridad y tránsito, los sensores de calles, los semáforos, los distintos vehículos y sus GPS, las llamadas de emergencias o reportes, entre otros. Si consideramos que es una ciudad grande donde hay miles de dispositivos que aportan a la obtención de información, una ciudad podría llegar a manejar petabytes de datos.

- **Velocidad: ¿Los datos se procesan en tiempo real o por lotes? ¿Por qué esa velocidad es crucial para el éxito de la empresa?**

En caso de la aplicación, gran parte de los datos se deben procesar en tiempo real, ya que si por ejemplo, un sensor detecta que hay demoras por tránsito, se debe reaccionar rápidamente modificando semáforos o enviando información a los conductores. Además, en caso de cualquier llamada de emergencia, del poder procesar rápidamente la información es de suma importancia y es por eso que la velocidad del procesamiento de datos es crucial para el éxito de la empresa

- **Variedad: ¿Qué tipos de datos se utilizan (estructurados, no estructurados, semi-estructurados)?**

Pueden haber datos estructurados, como por ejemplo el registro de sensores, velocidades de vehículos o la cantidad de vehículos que hay. También datos semi-estructurados como los de GPS (que tienen cierto orden pero de forma más flexible) y además no estructurados como videos de cámaras, imágenes, audios de llamadas, y reportes de ciudadanos, que son más archivos libres.

- **Veracidad: ¿Qué desafíos de calidad y confiabilidad de datos podrían enfrentar?**

En la aplicación, los desafíos que pueden llegar a tener los datos son que pueden haber errores, como por ejemplo: que los sensores dejen de funcionar por errores o desgaste, que las cámaras tengan mala calidad, que el GPS sea impreciso, o que haya reportes de ciudadanos falsos lo cual es difícil de controlar. Es por esta razón que es necesario validar, limpiar y contrastar los datos antes de utilizarlos para tomar decisiones.

- **Valor: ¿Cuál es el beneficio de negocio (ganancias, eficiencia, satisfacción del cliente) que se obtiene del Big Data en este caso?**

El beneficio de negocio que se obtiene del Big data en el caso de la aplicación Smart City, es el poder transformar los datos en decisiones útiles como reducir embotellamientos, disminuir los tiempos de viaje, mejorar la rapidez de respuesta ante emergencias, optimizando el uso de policías y ambulancias, lo cual conlleva a aumentar la seguridad y calidad de vida de los ciudadanos.

- **2. Almacenamiento:**

- **¿Dónde se almacenarán estos datos? ¿Creen que sería un sistema de archivos distribuido como HDFS, un Data Lake o una base de datos más tradicional?**

En esta gestión del tráfico se almacenaría una gran cantidad de información de cámaras, sensores de tránsito, llamadas de emergencia, redes sociales y reportes de ciudadanos. Los datos pueden ser bastante variados y ocupar mucho espacio, por lo que conviene utilizar Data Lake, que permite guardar grandes volúmenes de información en distintos formatos. Dentro de Data lake podría utilizarse un sistema distribuido como HDFS o tecnologías similares, porque permiten repartir la información entre muchos servidores y seguir aumentando la capacidad a medida que crecen los datos.

- **¿Qué desafíos de escalabilidad y costo enfrentarían al almacenar estos datos?**

En cuanto a la escalabilidad el principal desafío sería que la cantidad de datos crecería constantemente, ya que las cámaras y sensores generan información todo el tiempo. El sistema debería de aumentar su capacidad de almacenamiento a medida que se van agregando más dispositivos y datos.

Sobre los costos, almacenar gran cantidad de imágenes (por ejemplo de las patentes o autos) puede ser muy costoso. También habría gastos de almacenamiento en la nube, mantenimiento, seguridad y copias de respaldo. Sería importante decidir qué información habrá que conservar y durante cuánto tiempo.

○ **3. Procesamiento y Análisis:**

■ **¿Qué tipo de procesamiento se necesita (por lotes o en streaming)?**

Se necesita un tipo de procesamiento en streaming, porque los datos de cámaras y sensores de tránsito llegan constantemente y deben analizarse casi en tiempo real. También para este tipo de gestión debe analizarse los datos de las cámaras y sensores constantemente y en tiempo real. Esto permitiría detectar accidentes, situaciones de riesgo o exceso de tráfico. Procesamiento por lotes quizá podría servir para analizar datos históricos y encontrar patrones a lo largo del tiempo

■ **¿Qué herramientas de análisis serían las más adecuadas (ej. SQL, Python, machine learning)?**

SQL; para consultar datos estructurados

Python para poder procesar y analizar grandes cantidades de información.

Machine Learning para detectar patrones y así poder predecir congestiones o identificar zonas de mayor riesgo.

○ **4. Gobernanza y Seguridad:**

■ **¿Qué datos sensibles o personales podrían estar manejando? (ej. datos personales de clientes, historial de navegación)?**

Los datos sensibles que se podrían estar manejando son las imágenes de personas captadas en cámaras, los patentes de vehículos, la ubicación de cada uno por GPS, los datos personales en las llamadas de emergencia, la información de los ciudadanos en los reportes. Con estos datos se puede identificar directamente a una persona o conocer sus movimientos lo que implica que son datos personales y de cierto modo confidenciales.

■ **¿Qué desafíos de seguridad y privacidad tendrían que considerar para proteger la información?**

Los principales riesgos de este tipo de información es el tener acceso no autorizado a estos datos, el robo de los datos, el uso indebido de cámaras, el seguimiento excesivo e innecesario de ciudadanos, la filtración de información personal, el uso incorrecto de algoritmos de predicción, entre otros. Mientras que las medidas de seguridad que deberían implementar sería el cifrado de datos, que haya control de acceso, autenticación, que haya regularizaciones y políticas claras sobre quién puede acceder a los datos, que haya un cumplimiento de leyes de protección de datos, un seguimiento, entre otros.

4. Presentación de Hallazgos:

○ **Al finalizar el tiempo de discusión, cada grupo presentará un resumen de su análisis al resto de la clase. El objetivo es compartir una visión integral del caso de estudio, conectando todos los puntos analizados.**