

DATA LAKE & DATA WAREHOUSE

CÓMO LAS EMPRESAS ALMACENAN, ORGANIZAN Y
UTILIZAN GRANDES VOLÚMENES DE DATOS

¿POR QUÉ NECESITAMOS ALMACENAR TANTOS DATOS?



EL PROBLEMA

- Las empresas generan datos constantemente en múltiples formatos.
- Datos aislados en "silos" operativos.
- Incapacidad de analizar información heterogénea (tablas, texto, imágenes) en tiempo real.

OBJETIVO

- Centralizar la información para la toma de decisiones.
- Garantizar calidad, velocidad y gobernanza de datos.
- Extraer valor analítico y predecir tendencias.

LA LÍNEA DEL TIEMPO

EVOLUCIÓN DE LAS ARQUITECTURAS DE DATOS

1. BASES DE DATOS RELACIONALES: TRANSACCIONALES (OLTP).
2. DATA WAREHOUSE: ANALÍTICAS ESTRUCTURADAS (OLAP).
3. BIG DATA: EXPLOSIÓN EN VOLUMEN, VARIEDAD Y VELOCIDAD.
4. DATA LAKE: ALMACENAMIENTO MASIVO SIN ESTRUCTURA PREVIA.
5. DATA LAKEHOUSE: LO MEJOR DE LOS DOS MUNDOS EN UNA SOLA CAPA.



DATA WAREHOUSE (DWH)

REPOSITORIO CENTRALIZADO DE DATOS
ALTAMENTE ESTRUCTURADOS Y LIMPIOS PARA
ANÁLISIS ESTRATÉGICO

¿Cómo funciona? (Schema-on-Write)

- Enfoque ETL: Extract → Transform → Load.
- Se define el esquema/estructura ANTES de guardar los datos.
- Ventaja: Consultas SQL ultrarrápidas y datos de alta calidad.
- Limitación: Rígido ante cambios y costoso para datos no estructurados.




DATA LAKE

REPOSITORIO CENTRAL QUE ALMACENA DATOS CRUDOS EN SU FORMATO ORIGINAL (ESTRUCTURADOS, SEMI-ESTRUCTURADOS Y NO ESTRUCTURADOS).

¿Cómo funciona? (Schema-on-Read)

- Enfoque ELT: Extract → Load → Transform.
- Se guarda primero; el esquema se define AL LEER los datos.
- Ventaja: Almacenamiento económico, flexible y escala masivamente.
- Limitación: Requiere gobernanza para evitar el desorden.



DATA LAKE VS. DATA WAREHOUSE

Criterio	Data Warehouse	Data Lake
Tipo de datos	 Solo estructurados	 Todos (RAW, JSON, MP4, CSV)
Esquema	 Schema-on-Write	 Schema-on-Read
Costo / Escala	 Elevado / Rígido	 Económico / Altamente escalable
Usuarios	Analistas de Negocio (BI) 	Científicos e Ingenieros de Datos 

E-COMMERCE Y EL RIESGO DE UN DATA SWAMP

Ejemplo Práctico de E-Commerce:

- Data Lake guarda: Logs de clics, imágenes de productos, reviews en audio.
- Data Warehouse guarda: Transacciones de pago, facturación y stock.

¿Qué pasa si diseñamos mal un Data Lake? → Data Swamp

- Causa: Falta de catálogo, metadatos y control de acceso.
- Consecuencia: Datos inencontrables, duplicados, obsoletos e inútiles para el negocio.



LA SOLUCIÓN MODERNA: DATA LAKEHOUSE

¿Qué es el Data Lakehouse?

Una arquitectura abierta que combina la flexibilidad/bajo costo del Data Lake con la gobernanza, transacciones ACID y velocidad del Data Warehouse.

Relación con las 5 V:

- Volumen & Variedad: Soportados por el almacenamiento del Lake.
- Velocidad & Veracidad: Garantizadas por la capa de gestión ACID del DWH.
- Valor: Resultado directo de analizar todo en un solo lugar.

CONCLUSIONES

Puntos Clave para Recordar:

- La evolución responde a la necesidad de procesar más variedad a menor costo.
- DWH = Estructura y BI. Data Lake = Flexibilidad y Ciencia de Datos.
- El Data Lakehouse es el estándar moderno unificado.
- Sin gobernanza, cualquier Data Lake se convierte en un pantano inutilizable.

